

Miglotoji logika

Doc. dr. Agnė Paulauskaitė-Tarasevičienė

Situacijų aprašymas

Didžioji dalis tiksliai žinomų faktų aprašoma kiekybine forma. Tai įvairūs rodikliai, kiekiai, procentai ir t.t.:

- **2,5 karto;**
- **18,6 kg;**
- **40%,...**

Dalis faktų charakterizuojama verbaline (žodine) kalba:

- “mažas”, “vidutinis”,... *uždarbis*;
- “senas”, “jaunas”,... *žmogus*;
- “aukštas”, “žema”,... *temperatūra*,...

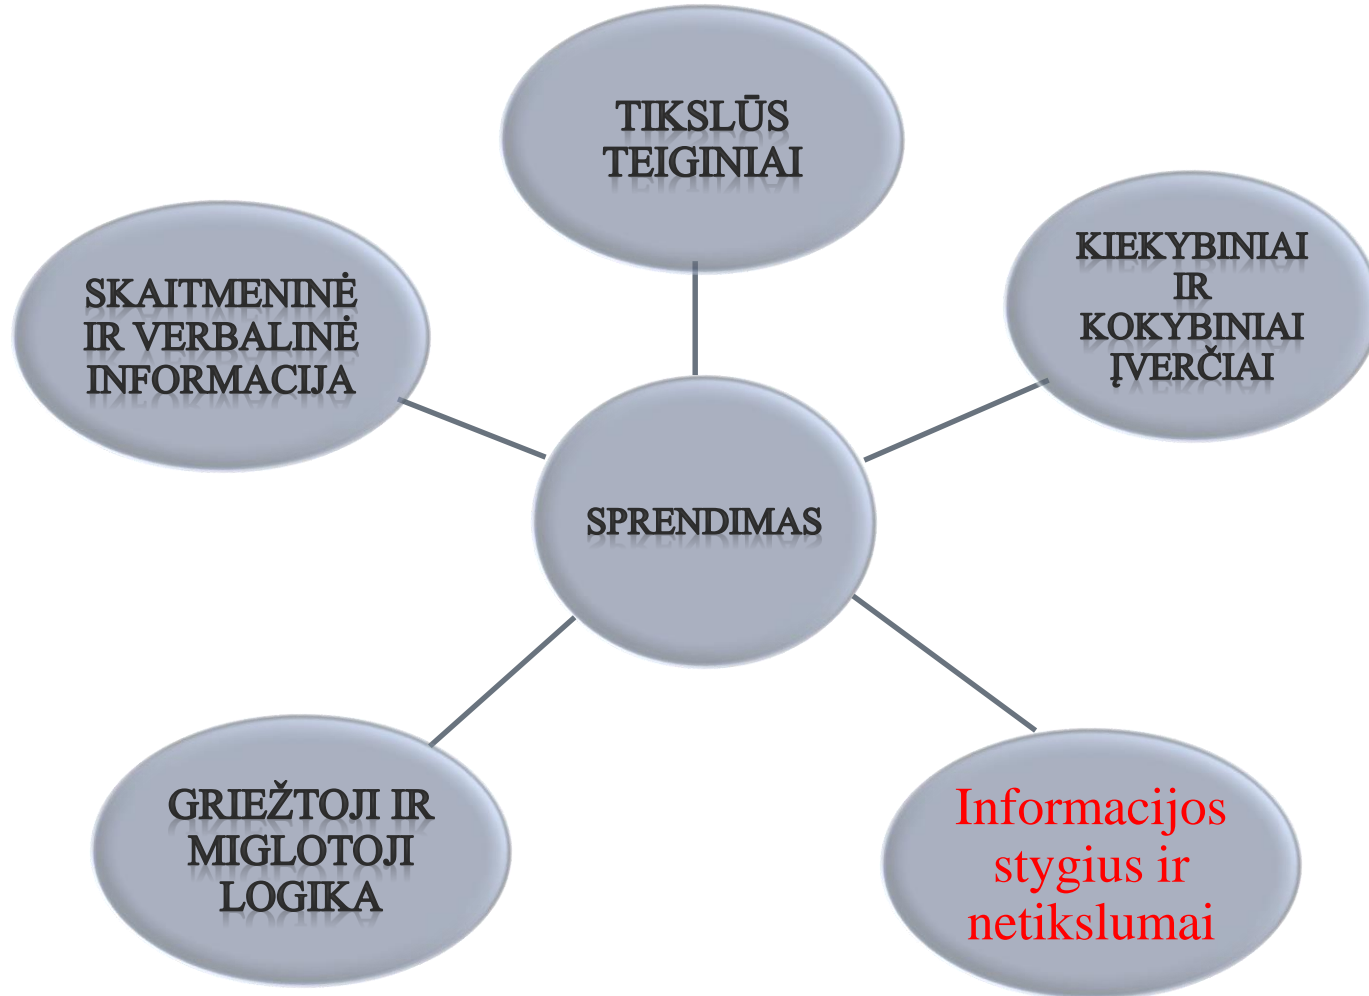
Informacijos netikslumas

Dviprasmiški ir netikslūs teiginiai aprašantys situacijas:

- **Maždaug** 5 litai,
- **Trupuči** didesnis,
- **Turbūt** padidės,
-

Ko gero mes trise pradėję verslą ir investavę apytikriai po 10 tūkst. EUR maždaug po dviejų metų uždirbsime apie 1 mln. EUR. Taigi kokia dalis maždaug tektų kiekvienam.?

Informacijos situacijų aprašymo charakteristikos



Logika

Turint sudėtingas situacijas charakterizuojančius aprašus, jų analizei netinka vien tik griežtoji logika (*dvejjetainė Būlio* paremtais teiginiais) :

- **Taip – Ne,**
- **Tiesa – Melas,**
- **1 – 0.**

Būtina naudoti aritmetines, žmogaus samprotavimams būdingas logikos rūšis.

Paprastoji (*miglotoji logika*) artimiausia žmogaus samprotavimui ir mąstymui.

Situacijų aprašymų norminimas

Neformaliai ir miglotai pateiktas nagrinėjamos situacijos aprašas dar netinka tiesiogiai apdoroti kompiuteriu.

Visi miglotųjų situacijų aprašai turi būti **sunorminti**.

Tegul S situaciją ekspertas charakterizuoja savybių įverčių rinkiniu

$$\{C_1, \dots, C_i, \dots, C_M\}$$

C_i , – gali būti skaitinis (pvz., 14) arba verbalinis (pvz., mažas).

Verbaliniams kintamiesiems suteikus kiekybinius įverčius, visos C_i reikšmės tampa skaitinėmis.

$$C_i \in [C_{imin}, C_{imax}], \forall_i$$

Norminimas

- Tam, kad įverčiai būtų išmatuojami ir tarpusavyje palyginami, įvedamas norminimas:

$$B_i = \frac{C_i - C_{i \min}}{C_{i \max} - C_{i \min}} \times K$$

K – mastelinis koeficientas, įvedamas skaičiavimų patogumui (pvz., $K=1,10$ ir pan.)

Norminimas

- Suformuojama situacijos pirminio įverčio C_i ir sunorminto įverčio B_i atitiktis:

$$\begin{cases} C_{i \min} = 0, & C_{i \max} = C & \forall_i \\ \textit{Atitiktis } C_i \leftrightarrow B_i \\ B_i \in [0, K] \end{cases}$$

- Suformuojamas S situacijos savybių įverčių rinkinys:

$$\{B_1, \dots, B_i, \dots, B_M\}$$

Įverčių rinkinio plėtiniai

- Ekspertai gali suformuoti ir papildomas savybes (rinkinio plėtinis):

$$\begin{aligned} & \{A_1, \dots, A_j, \dots, A_N\} \quad j = \{1, 2, \dots, N\}, N > M \text{ ir} \\ & \begin{cases} \text{jeigu } j = \{1, 2, \dots, M\} \text{ tai } A_j = B_j \\ \text{jeigu } j = \{M + 1, \dots, N\} \text{ tai } A_j = \Psi(B_i, \dots, B_k) \end{cases} \\ & i, k = \{1, 2, \dots, M\} \end{aligned}$$

- Plėtiniam naudojamos įvairios matematinės ir loginės funkcijos Ψ . Pavyzdžiui:

$$\Psi(B_i, \dots, B_k) = \frac{1}{L} \sum_{l=i}^k B_l, \quad L - \text{aibės } \{i, \dots, k\} \text{ galia (skaicius)}$$

$$\Psi(B_i, \dots, B_k) = \min(B_i, \dots, B_k)$$

$$\Psi(B_i, \dots, B_k) = \max(B_i, \dots, B_k)$$

$$\Psi(B_i, \dots, B_k) = \max(B_i, \dots, B_k) - \min(B_i, \dots, B_k)$$

Situacijų aprašų norminimo pavyzdys

$$B_i = \frac{C_i - C_{i\min}}{C_{i\max} - C_{i\min}} \times K = \frac{17 - 10}{20 - 10} \times 10 = 7$$

C_1	C_2	C_3	C_4	$C_1 = [10-20] \leftrightarrow [0-10]$ $C_2 = [\text{zero}, \text{small}, \text{medium}, \text{big}] \leftrightarrow [0, 3, 6, 10]$ $C_3 = [N, E, S, W] \leftrightarrow [0, 2, 8, 10]$ $C_4 = [0\% - 100\%] \leftrightarrow [0-10]$
17 ←	zero	W	10 %	

K=10			
B_1	B_2	B_3	B_4
7 ←	0	10	1

B_1	B_2	B_3	B_4

Tarpusavio santykiai atvaizduoti sunormintais įverčiais pagal spalvos ryškumą

Situacijų aprašo plėtinys

$\{A_1, \dots, A_j, \dots, A_N\} \quad j = \{1, 2, \dots, N\}, N > M$ ir

$\begin{cases} \text{jeigu } j = \{1, 2, \dots, M\} \text{ tai } A_j = B_j \\ \text{jeigu } j = \{M+1, \dots, N\} \text{ tai } A_j = \Psi(B_i, \dots, B_k) \end{cases}$

$i, k = \{1, 2, \dots, M\}$

$$\Psi(B_i, \dots, B_k) = \min(B_i, \dots, B_k)$$

$$\Psi(B_i, \dots, B_k) = \max(B_i, \dots, B_k)$$

$$\Psi(B_i, \dots, B_k) = \max(B_i, \dots, B_k) - \min(B_i, \dots, B_k)$$

B ₁	B ₂	B ₃	B ₄
7	0	10	1

B ₁	B ₂	B ₃	B ₄

A ₁	A ₂	A ₃	A ₄	A ₅	A ₆
7	0	10	1	0	10


Išplėta

$A_5 = \min(B_1, B_3) =$
 $A_6 = \max(B_1, B_4) =$

Vertinimas

- Vienas iš Migtosios Logikos (ML) aibių pavyzdžių yra aibė aukštų žmonių. Ką reiškia teiginys aukštas? Tokį teiginį skirtingai supranta skirtingi vertintojai.
- Vienaip teiginį *aukštas* supranta logikos **ekspertas** vertindamas krepšininko ūgį, kitaip supranta aukštas krepšinio **rinktinės treneris**, dar kitaip **mergina**.


•




Teiginių ir įverčių tikrumo funkcijos

- Negalima vertinti kategoriškai savybių, kurių įverčiai pateikti miglotai, kokybiniais rodikliais, kai informacija nėra tiksli, laukiami sprendimai yra nauji ir t.t.

*Kategoriškas
vertinimas*



*Nekategoriškas
vertinimas*



Teiginio tikrumo funkcija

- Teiginio tikrumo funkcijos (toliau TTF) suformavimas remiasi elemento priklausomybės aibei įverčiu. Jei elementas x_0 gali tik priklausyti aibei D , arba nepriklausyti tai tikrumo funkcija yra:

$$\mu_D(x) = \begin{cases} 1, & x_0 \in D \\ 0, & x_0 \notin D \end{cases}$$

- Jei elemento x_0 priklausomumo aibei F tikrumo laipsnis gali būti tolydinė reikšmė iš intervalo $[0,1]$, tai elemento priklausomumo aibei F funkcija yra tolydinė, kaip pavyzdžiui:

$$\mu_F(x) = \frac{1}{1 + 10(x - x_0)^2}$$

Teiginio tikrumo funkcija

Bivalentinė logika:

$$D = \{x_0\}$$

$$\mu_D(x) = \begin{cases} 1, & x_0 \in D \\ 0, & x_0 \notin D \end{cases}$$


Miglotoji logika:

$$F = \{(x, \mu_F(x)) \mid \mu_F \in C\}$$


$$C = [0,1]$$

$$\mu_F(x) = \frac{1}{1 + 10(x - x_0)^2}$$

Teiginio tikrumo funkcija $\mu(X)$




Tiksliai 10



Maždaug 10

$x \in X$ $\mu(x)=[0,1]$ - teiginio tikrumo laipsnis



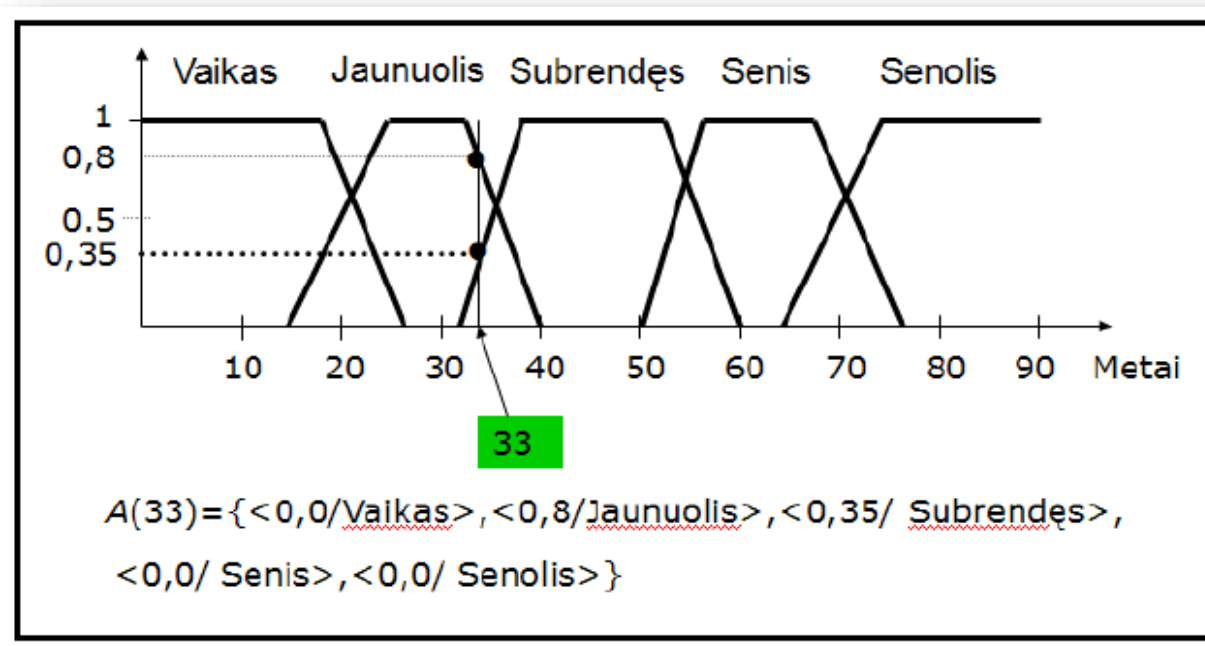
1 – labai akštas
 0.8 – aukštas
 0.5 – vidutinis
 0.2 – menkas
 0 – nulinis

Pavyzdys

Pavyzdžiui, jeigu gyvybės draudimo kompanijos ekspertai visus asmenis pagal amžių vertina tikrumo funkcijomis, tai 33 metų asmuo būtų charakterizuojamas tokia verbalinių įverčių eilute

$$\text{TEIGINYS} = \{ \langle \text{skaitinis tikrumo įvertis} / \text{verbalinis įvertis} \rangle \}$$

$$A(33) = \{ \langle 0,0 / \text{Vaikas} \rangle, \langle 0,8 / \text{Jaunuolis} \rangle, \langle 0,35 / \text{Subrendęs} \rangle, \\ \langle 0,0 / \text{Senis} \rangle, \langle 0,0 / \text{Senolis} \rangle \}$$




Amžiaus vertinimo tikrumo funkcijos pavyzdys

Priklausomybės funkcijos

- Egzistuoja įvairių tipų priklausomybės (angl. *membership*) funkcijų: trikampė, trapezoidinis, varpelio formos, Gausinės kreivės, polinominės kreivės ar sigmoidinės funkcijos.

Trikampės kreivės priklauso nuo trijų parametrų a , b , ir c


$$f(x; a, b, c) = \begin{cases} 0 & \text{for } x < a \\ \frac{x - a}{b - a} & \text{for } a \leq x < b \\ \frac{c - x}{c - b} & \text{for } b \leq x \leq c \\ 0 & \text{for } x > c \end{cases}$$



Kitos priklausomybės

Trapecinė kreivė priklauso nuo keturių parametru


$$f(x; a, b, c, d) = \begin{cases} 0 & \text{for } x < a \\ \frac{x - a}{b - a} & \text{for } a \leq x < b \\ 1 & \text{for } b \leq x < c \\ \frac{d - x}{d - c} & \text{for } c \leq x < d \\ 0 & \text{for } d \leq x \end{cases}$$



π- formos funkcija pateikta žemiau


$$f(x; b, c) = \begin{cases} S(x; c - b, c - b/2, c) & \text{for } x \leq c \\ 1 - S(x; c, c + b/2, c + b) & \text{for } x > c \end{cases}$$

$$S(x; a, b, c) = \begin{cases} 0 & \text{for } x < a \\ \frac{2(x - a)^2}{(c - a)^2} & \text{for } a \leq x < b \\ 1 - \frac{2(x - c)^2}{(c - a)^2} & \text{for } b \leq x \leq c \\ 1 & \text{for } x > c \end{cases}$$




Kitos priklausomybės


Gauso priklausomybė




Sigmoidinė



Varpelio formos (generalized bell)



S-formos



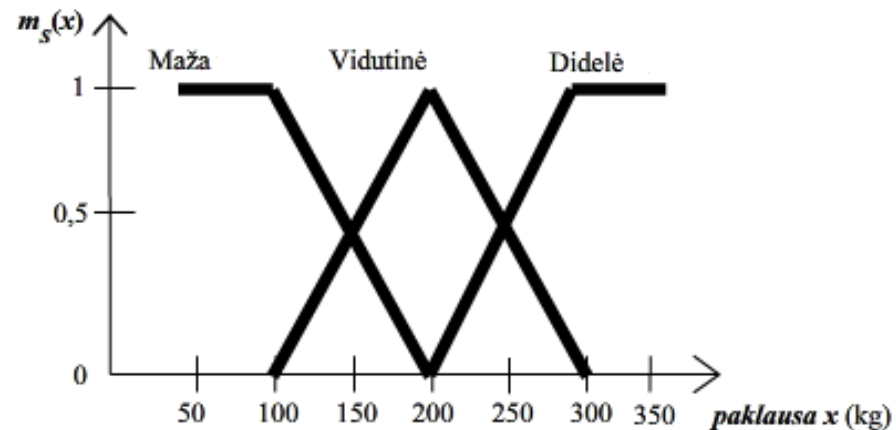

Skirtumai tarp neraiškos logikos ir tikimybių teorijos

1. Pagal pateiktą pavyzdį $x_0=125$, abiejų priklausomumo funkcijų suma $m_{maza}(125) + m_{vidutine}(125)=1 = 100\%$.

Tačiau bendru atveju ML teorija **nereikalauja** kad suma būtų lygi 1. Tikimybių teorijoje $P(H_1) + P(H_2) = 1$


kur H_1 ir H_2 – pilnos įvykių grupės

2. ML tegali įvykti tik vienas pilnos įvykių grupės įvykis H_1 arba H_2 , bet ne **abu kartu**.
3. Tikimybė nusako galimybę įvykti iš anksto prieš eksperimentą, o ML modeliuoja jau įvykusius įvykius.



Miglotoji aritmetika

- Sprendimų analizės ekspertai paprastai kiekvieną miglotą skaičių vaizduoja tam tikra tikrumo funkcija, kurios pavidalas priklauso nuo eksperto patirties, nagrinėjamos situacijos ir pan.
- Pavyzdyje tikrumo funkcijos kreivė yra pavaizduotas miglotasis skaičius **A** (maždaug 6). Miglotosios aritmetikos veiksmai su tokiais skaičiais vykdomi kiekviename α -kirtimo taške.
- Migloto skaičiaus įvertis atspindimas intervale $[\alpha_1, \alpha_2]$





Aritmetikos veiksmai

- Apibendrintai bet kurį miglotosios aritmetikos veiksmą su dviem miglotais skaičiais A ir B bei to veiksmo miglotąjį rezultatą C galima aprašyti tokia operacija

$$A \circ B = C$$

- Čia \circ reiškia bet kokį aritmetikos veiksmą “+”, “-”, “ \times ”, “ \div ”.



Miglotosios logikos veiksmiai

Jeigu turėsime miglotąsias reikšmes jos ekstremumuose **1** (visiška *tiesa*) arba **0** (visiška *netiesa*), tai gali būti taikomos standartinės loginės operacijos.

Tam kad apibrėžti miglotosios logikos operatorius, reikia apibrėžti operatorius, kurie saugoja rezultatus tokių operacijų kaip AND, OR, ir NOT.

Atsakymas yra *min*, *max* ir *complement* operacijos.

Konjunkcijos operacija


A	B	A and B
0	0	0
0	1	0
1	0	0
1	1	1

AND

Bendresne formule galima parašyti formulę:

$$A \& B = \min(A, B).$$

Grafinis operacijos atvaizdavimas



Disjunkcijos operacija

A	B	A or B
0	0	0
0	1	1
1	0	1
1	1	1

OR

Bendresne forma galima parašyti formulę:

$$A \text{ OR } B = \max(A, B).$$

Grafinis operacijos atvaizdavimas



OR

$\max(A, B)$



Inversijos operacija


A	not A
0	1
1	0

NOT

Bendresne formule galima parašyti formulę:

$$\text{NOT } A = 1 - A$$

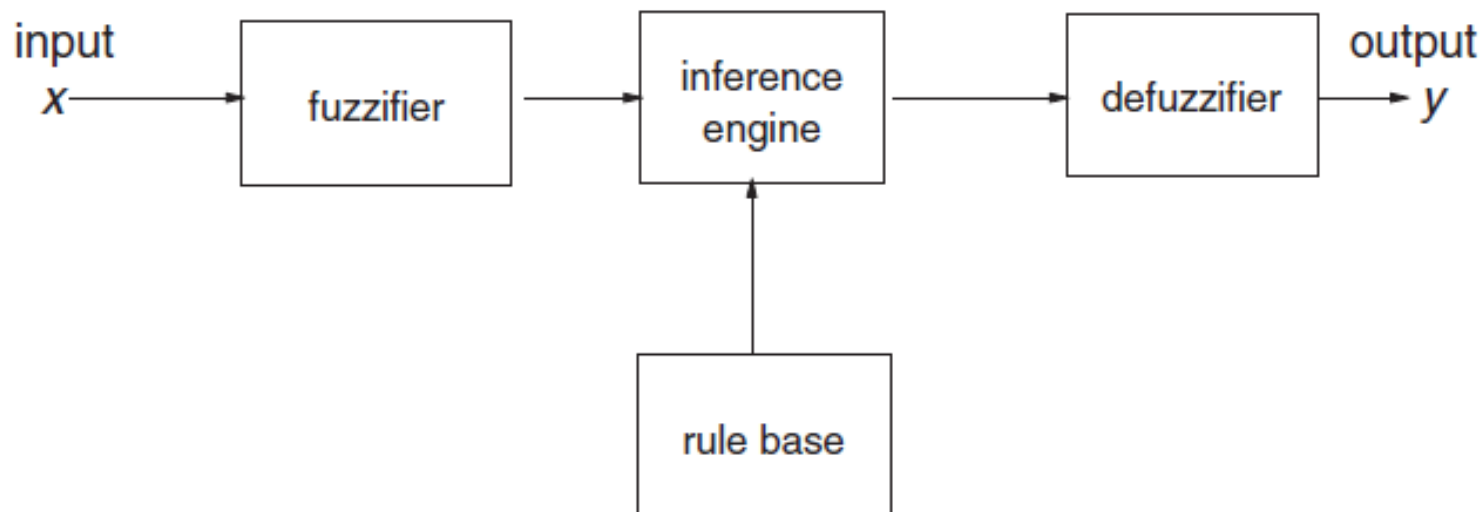




Situacijų aprašymai žinių inžinerijoje

Fuzzy išvadų darymo sistema

- **Fuzzy išvadų sistema (FIS)** apibrėžia netiesinį įėjimo duomenų vektorių atvaizdavimą į išėjimą, naudojant fuzzy taisykles.
- Atvaizdavimo procesas įtraukia įėjimo/išėjimo priklausomybės funkcijas, FL operatorius, fuzzy **IF-THEN** taisykles, išėjimo aibių agregaciją ir defuzifikaciją.



FIS veikimas

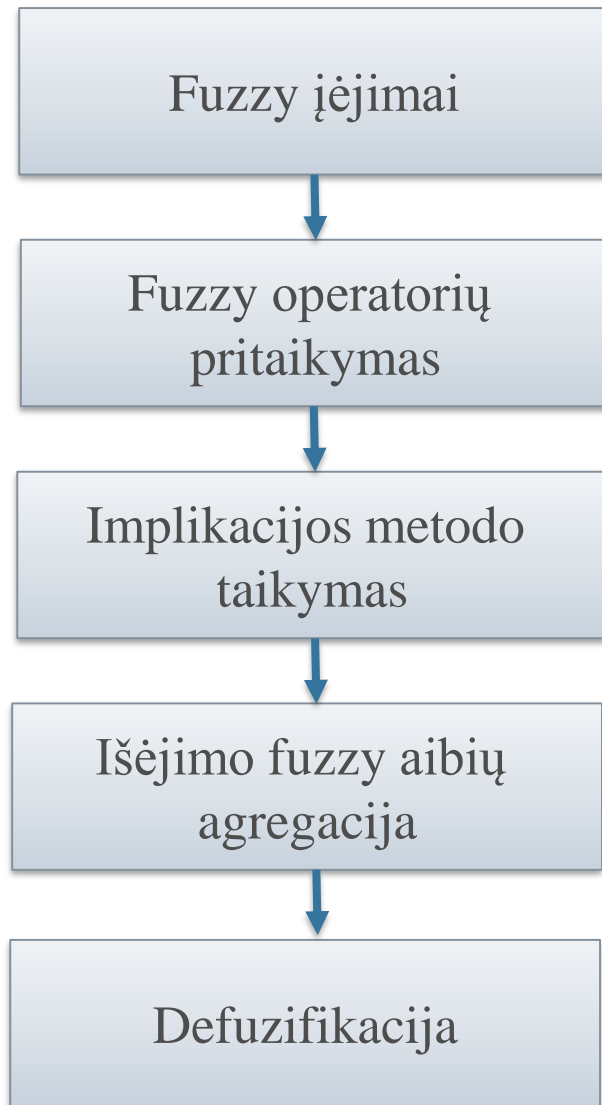
FIS susideda iš keturių svarbiausių komponentų: *fuzifikatorius*, *išvadų sistema*, *taisyklių bazė* ir *defuzifikatorius*.

- **Taisyklių sudarymas:** Taisyklių bazė apima lingvistines taisykles, kurios yra sudaromos ekspertų.
- **Taisyklių atvaizdavimas:** Fuzifikatorius atvaizduoja įėjimo skaičius į atitinkamas fuzzy priklausomybes. Tai yra būtina, tam kad aktyvuoti taisykles, kurios pateiktos lingvistiniais kintamaisiais. Fuzifikatorius paima įėjimo kintamuosius ir nustato priklausomybės laipsnį kiekvienai fuzzy aibei.
- **Išvadų sistema:** apibrėžia įėjimo fuzzy aibių atvaizdavimo sistemą į išėjimo fuzzy aibes. Sistema nustato laipsnį, kuriame yra tenkinamas „*antecedent*“ (įėjimo atributas) kiekvienoje iš taisyklių.

FIS veikimas

- **Taisyklių aktyvavimas:** Gali būti kad daugiau negu viena taisyklė yra aktyvuojama vienu metu. Tokiu atveju visų taisyklių išėjimai yra agreguojami.
- **Agregacija:** Agregacijos metu, fuzzy aibes, kurios atvaizduoja kiekvienos taisyklės išėjimus yra sujungiamos į vieną fuzzy aibę. (Fuzzy taisyklės yra „paleidžiamos“ lygiagrečiai. Tvarka kaip bus paleidžiamos taisyklės nėra svarbios išėjimui.)
- **Defuzifikacija:** Defuzifikatorius atvaizduoja išėjimo fuzzy aibes į tikslų skaičių. Yra keletas defuzifikacijos metodų, tačiau pats populiariausias yra „centroid“ (svorio centro skaičiavimas).

FIS žingsniai



Paimti įėjimus ir nustatyti priklausomybės laipsnius

Nustatomi aktyviųjų taisyklių stiprumai taikant loginius operatorius.

*Implikacijos metodas - išėjimo priklausomybių funkcijų atvaizdavimas remiantis aktyviųjų taisyklių stiprumais. Dažniausiai naudojamos du metodai: **min** ir **prod**.*

Procesas kur paskaičiuojamas kiekvienos taisyklės išėjimas.

Paskaičiuojama tiksli išėjimo reikšmė

Pavyzdys

Problema yra nustatyti rizikos lygį programinės įrangos diegimo projekte.

Tarkime mūsų sprendimas priklauso nuo dviejų įėjimų:

- Projekto finansavimas;
- Įdarbintas personalas.



Įėjimo reikšmių paruošimas


Tikslios reikšmės paverčiamos į fuzzy.

- Du kintamieji:
 - pirmas -> į projekto finansavimo lygis;
 - antras - > projekto personalo lygis (dydis).
- Tarkime turime tokias reikšmes:
 - projekto finansavimas **35%**
 - Projekto personalo įdarbinimas **60%**

Pavyzdys. Fuzzy Aibės

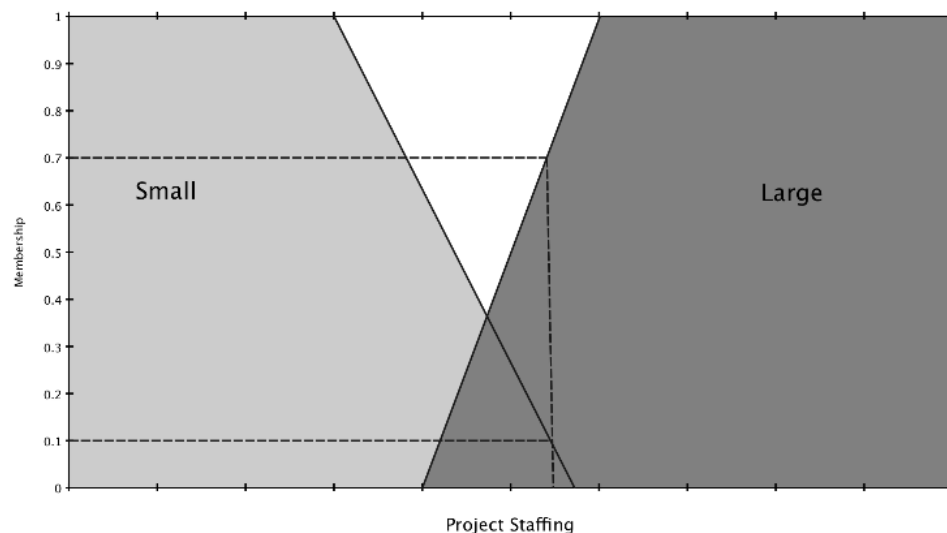
Aibės kurios apibrėžia
projekto finansavimą:

**inadequate, marginal ir
adequate.**



Aibės apibrėžiančios
personalo dydį yra:

small and large.




Fuzzy reikšmių paskaičiavimas. Finansavimas

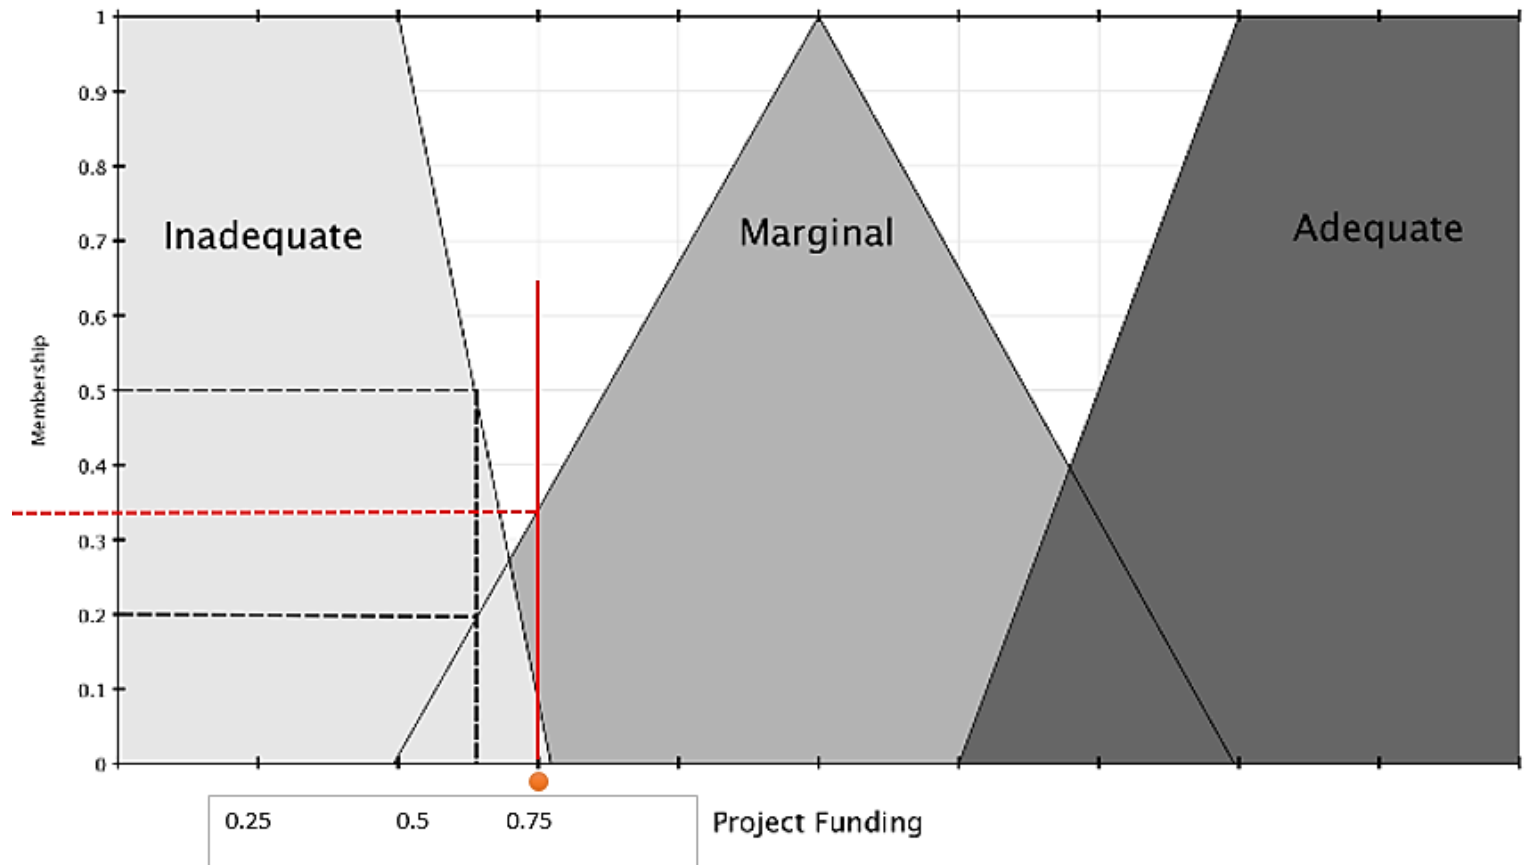
$$\mu_{\text{funding=inadequate}}(35) = 0.5$$

$$\mu_{\text{funding=marginal}}(35) = 0.2$$

$$\mu_{\text{funding=adequate}}(35) = 0.0$$

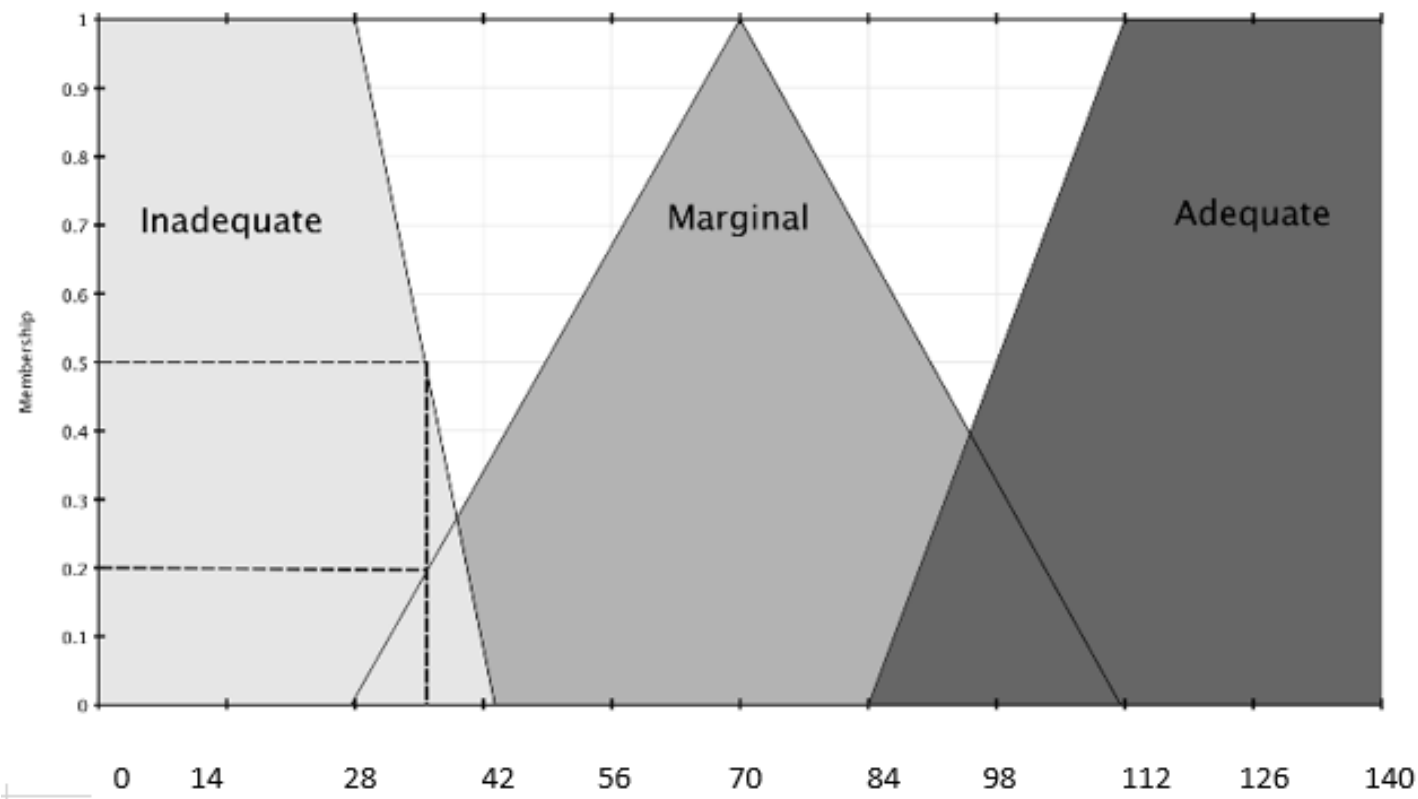


Kaip skaičiuojama?



$$f(x; a, b, c) = \begin{cases} 0 & \text{for } x < a \\ \frac{x - a}{b - a} & \text{for } a \leq x < b \\ \frac{c - x}{c - b} & \text{for } b \leq x \leq c \\ 0 & \text{for } x > c \end{cases}$$

Paskaičiuokite reikšmes iš formulių




$$f(x; a, b, c, d) = \begin{cases} 0 & \text{for } x < a \\ \frac{x-a}{b-a} & \text{for } a \leq x < b \\ 1 & \text{for } b \leq x < c \\ \frac{d-x}{d-c} & \text{for } c \leq x < d \\ 0 & \text{for } d \leq x \end{cases}$$

$$f(x; a, b, c) = \begin{cases} 0 & \text{for } x < a \\ \frac{x-a}{b-a} & \text{for } a \leq x < b \\ \frac{c-x}{c-b} & \text{for } b \leq x \leq c \\ 0 & \text{for } x > c \end{cases}$$

Fuzzy reikšmių paskaičiavimas. Personalas

$$\mu_{\text{staffing=small}}(60) = 0.1$$

$$\mu_{\text{staffing=large}}(60) = 0.7$$



Taisyklių sudarymas

Fuzzy taisyklių sudarymas:

1. Jeigu projekto finansavimas yra **adequate** arba *personalas* yra **small** tai rizika yra **low**.
2. Jeigu *projekto finansavimas* yra **marginal** ir *personalas* yra **large** tai rizika yra **normal**.
3. Jeigu *projekto finansavimas* yra **inadequate** tai rizika yra **high**

TAISYKLIŲ PASKAIČIAVIMAI

Loginė operacija **or**. *max* ir *probor* metodai

Taisyklė 1. Jeigu projekto finansavimas yra **adequate** arba *personalas* yra **small** tai rizika yra **low**.

Loginės operacijos **or** ir *maksimalios vertės (max)* metodas.

Jei S_1 arba S_2 arba ... arba S_n tai **išvada**

teisingumas t yra skaičiuojamas pagal formulę

$$t = \max\{m_{S_1}(x_1); m_{S_2}(x_2); \dots m_{S_n}(x_n)\}$$

Loginės operacijos **or** ir *algebrinės sumos (probor)* metodas.

Jei S_1 arba S_2 tai **išvada**

teisingumas t yra skaičiuojamas pagal formulę

$$t = m_{S_1}(x_1) + m_{S_2}(x_2) - m_{S_1}(x_1)m_{S_2}(x_2)$$

Taisyklė Nr. 1

Loginės operacijos *or* ir *maksimalios vertės (max)* metodas.

$$\mu_{A \cup B}(x) = \max[\mu_A(x), \mu_B(x)]$$

$$\mu_{\text{risk=low}} = \max[\mu_{\text{funding=adequate}}(35), \mu_{\text{staffing=small}}(60)] = \max[0.0, 0.1] = 0.1$$

Loginės operacijos *or* ir *algebrinės sumos (probor)* metodas.

$$\mu_{A \cup B}(x) = \mu_A(x) + \mu_B(x) - \mu_A(x) * \mu_B(x)$$

$$\mu_{\text{risk=low}} = 0.0 + 0.1 - 0.0 * 0.1 = 0.1$$

Taisyklė Nr. 2

Taisyklė 2. Jeigu *projekto finansavimas* yra **marginal** ir *personalas* yra **large** tai rizika yra **normal**.

Loginės operacijos *and* ir minimalios vertės min metodas.

Jei S_1 ir S_2 ir ... ir S_n tai *išvada*

teisingumas t yra lygus minimaliam visų teiginių S_1, S_2, \dots, S_n teisingumui

$$t = m_{i\v{s}vada}(y) = \min\{m_{S_1}(x_1); m_{S_2}(x_2); \dots m_{S_n}(x_n)\}$$

$$\mu_{A \cap B}(x) = \min[\mu_A(x), \mu_B(x)]$$

$$\mu_{\text{risk=normal}} = \min[\mu_{\text{funding=marginal}}(35), \mu_{\text{staffing=large}}(60)] = \min[0.2, 0.7] = 0.2$$

Loginė operacija **and**. Metodas *prod*

Loginės operacijos *and* ir algebrinės sandaugos (*prod*) metodas.

Jei S_1 ir S_2 ir ... ir S_n tai *išvada*

teisingumas t yra skaičiuojamas pagal formulę

$$t = m_{S_1}(x_1) \cdot m_{S_2}(x_2)$$

$$\mu_{A \cap B}(x) = \mu_A(x) * \mu_B(x)$$

$$\mu_{\text{risk=normal}} = 0.2 * 0.7 = 0.14$$

Taisyklė Nr. 3

Jeigu *projekto finansavimas* yra **inadequate** tai rizika yra **high**.

$$\mu_{\text{risk=high}}(z) = 0.5$$


Agregacija. Visų taisyklių įverčiai:

$$\mu_{\text{risk=low}}(z) = 0.1$$

$$\mu_{\text{risk=normal}}(z) = 0.2$$

$$\mu_{\text{risk=high}}(z) = 0.5$$

Plačiau apie agregacijos būdus skaityti [čia](#)



Defuzifikacija

Defuzifikacija gali būti atliekama keliais skirtingais būdais. Pats populiariausias yra **centroid** metodas, kuris paskaičiuoja svorio centrą plotui esančiam žemiau kreivės


Kiti metodai:


- Bisector;
- Maksimumo vidurkio (angl. *Mean of maximum*);
- Mažiausio maksimumo (angl. *Smallest value of maximum*);
- Didžiausio maksimumo (angl. *Largest value of maximum*).

Išėjimo paskaičiavimas

$$COG = \frac{\sum_{x=a}^b \mu_A(x)x}{\sum_{x=a}^b \mu_A(x)}$$

$$COG = \frac{(0 + 10 + 20) * 0.1 + (30 + 40 + 50 + 60) * 0.2 + (70 + 80 + 90 + 100) * 0.5}{0.1 * 3 + 0.2 * 4 + 0.5 * 4} = 67.4$$





Miglotosios logikos aiškinimas per Ekspertinius planus

Ekspertinių planų samprata

Ekspertai žinias gali išreikšti loginių taisyklių pavidalu:

IF <...>, **THEN** <...>

Dažniausiai naudojamos 2 tipų taisyklės:

Mamdani taisyklė atrodo taip:

IF < x yra A > **AND** < y yra B > **THEN** < $z = C$ >

x , y , z yra skaitinė įverčio reikšmė, o A , B ir C yra jiems ekspertų priskirti migloti įverčiai.

Takagi Sugeno tipo taisyklė atrodo taip:

IF < x yra A > **AND** < y yra B > **THEN** < $z = F(x, y)$ >

Takagi-Sugeno taisyklė skiriasi nuo Mamdani tuom, kad teiginys einantis po THEN skaičiuojamas pagal formulę.

Taisyklių taikymas. Pavyzdys

Automatinis automobilio valdymas slidžiam kelyje, kai riedėjimo greitis x yra 90km/val. (A =“didelis greitis”), o atstumas iki kliūtis yra $y = 300$ m. (B = “labai mažas atstumas”), tai reikėtų vairą pasukti $z = 1^\circ$ (C =“truputį kairėn”).

Mamdami taisyklė:

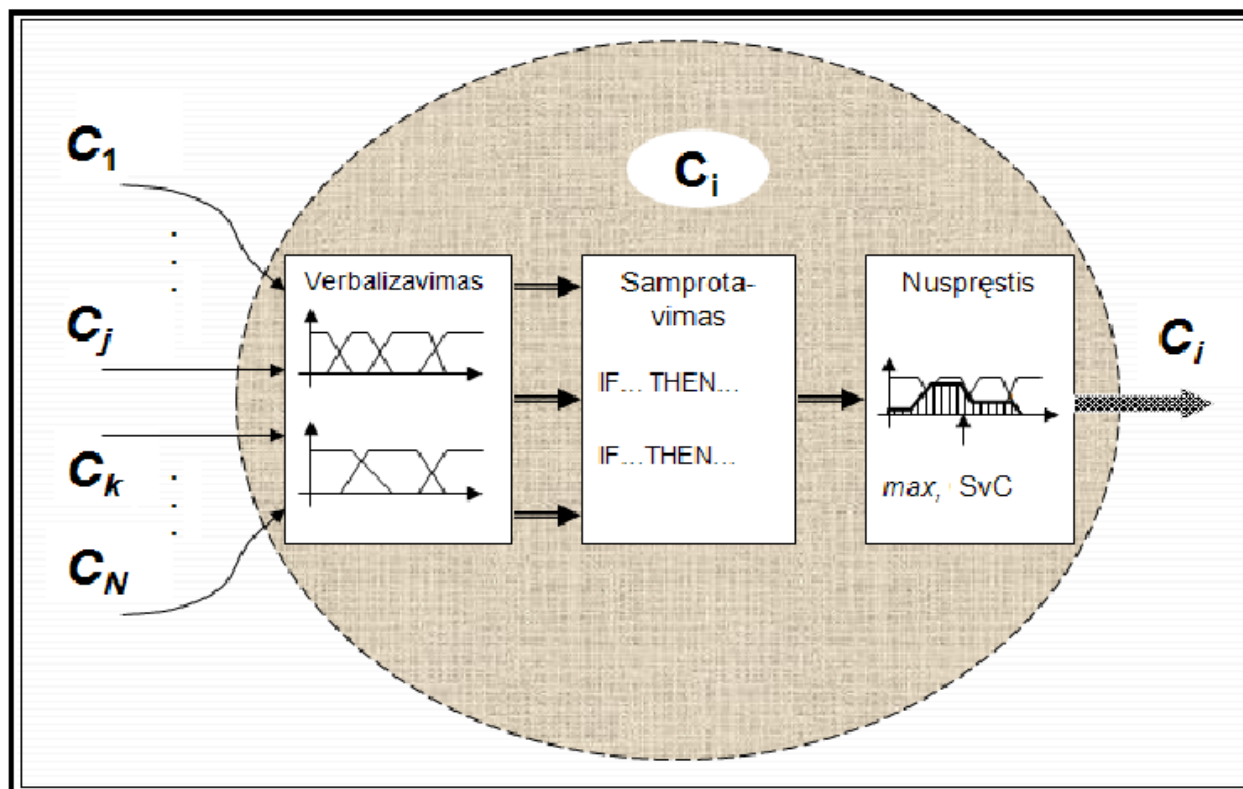
IF $\langle 90 \text{ yra “didelis greitis”} \rangle$ **AND** $\langle 300 \text{ yra “labai mažas atstumas”} \rangle$ **THEN** $\langle 1 = \text{“truputį kairėn”} \rangle$

Takagi-Sugeno taisyklė:

IF $\langle 90 \text{ yra “didelis greitis”} \rangle$ **AND** $\langle 300 \text{ yra “labai mažas atstumas”} \rangle$ **THEN** $\langle z = 3x/y \rangle$

MEP mazgo struktūra

- Sudėtingas patyrusių ekspertų žinias, paremtas ML ir IF/THEN taisyklėmis, patogiu perkelti į visų rūšių miglotuosius planus. Šitos ekspertinės žinios talpinamos MPP mazguose. Tokiu būdu vadinami miglotaisiais ekspertiniais planais (MEP).




Verbalizavimas

Verbalizavimas – tai tokia operacija, kurios metu esybę C_i įtakojančių veiksnių $C_1 - C_N$ skaitiniams įverčiams suteikiami miglotieji verbaliniai įverčiai ir jų tikrumas.

- *Pavyzdžiui:*

Skaitiniam įverčiam $C_k = 1,8$ m verbalizavimo operacija suteikia miglotąjį įvertį “Vidutinio ūgio” su tikrumu 0,2 ir miglotąjį įvertį “Aukštas” su tikrumu 0,8. Šie įverčiai perduodami samprotavimo blokui.



Samprotavimo blokas

Samprotavimo blokas atlieka tokias operacijas:

- 1) Esamam IF/THEN taisyklių sąrašo surašo konkrečius tikrumo įverčius, gaunamus iš verbalizavimo bloko;
- 2) Pagal turimus konkrečius teiginių tikrumo įverčius atliekamos miglotosios operacijos, numatytose sąrašo taisyklėse; loginės operacijos rezultatas – tai loginės taisyklės teiginio tikrumo skaitinis įvertis.
- 3) Loginių operacijų rezultatas persiunčiamas į nuspręsties bloką.

Nuspręsties blokas

1. Nuspręsties blokas pagrindinai vykdo tokias funkcijas: pagal gautus loginių taisyklių teiginių tikrumo skaitinius įverčius (β_i) apskaičiuojami jų sukuriamo miglotojo rezultato tikrumo įverčiai.
2. Juos apjungia miglotosios logikos operacija ir nustato gauto sumarino miglotojo įverčio svorio centro koordinatę, kuri yra rezultatas.

Tai galima padaryti keliais būdais, naudojant skirtingas formules.

Nuspręsties rezultato paskaičiavimas


1 būdas. Mamdani metodas

$$\mu_M(y) = \max_i [\min(\beta_i, \mu_i(y))]$$

$$y_{SvC} = \frac{\int_a^b y \mu_M(y) dy}{\int_a^b \mu_M(y) dy}$$

- Konjunkcijos operacija apjungia loginės taisyklės susijusios su i -tuoju rezultatu, teiginio tikrumo skaitinį įvertį β_i ir nuspręsties miglotojo rezultato y tikrumo funkciją $\mu_i(y)$.

Pavyzdys. Mamdani metodas



- Dvi galimos miglotojo rezultato y tikrumo funkcijos $\mu_1(y)$ ir $\mu_2(y)$.
- b) ir c) paveiksluose pateikti operacijų rezultatai:
 $\min(0,8 \mu_1(y))$ ir $\min(0,2 \mu_2(y))$
- Šie rezultatai apjungti miglotosios logikos disjunkcijos (\max) operacija ir taip suformuojama nuspręsties miglotojo rezultato tikrumo funkcija $\mu_M(y)$.

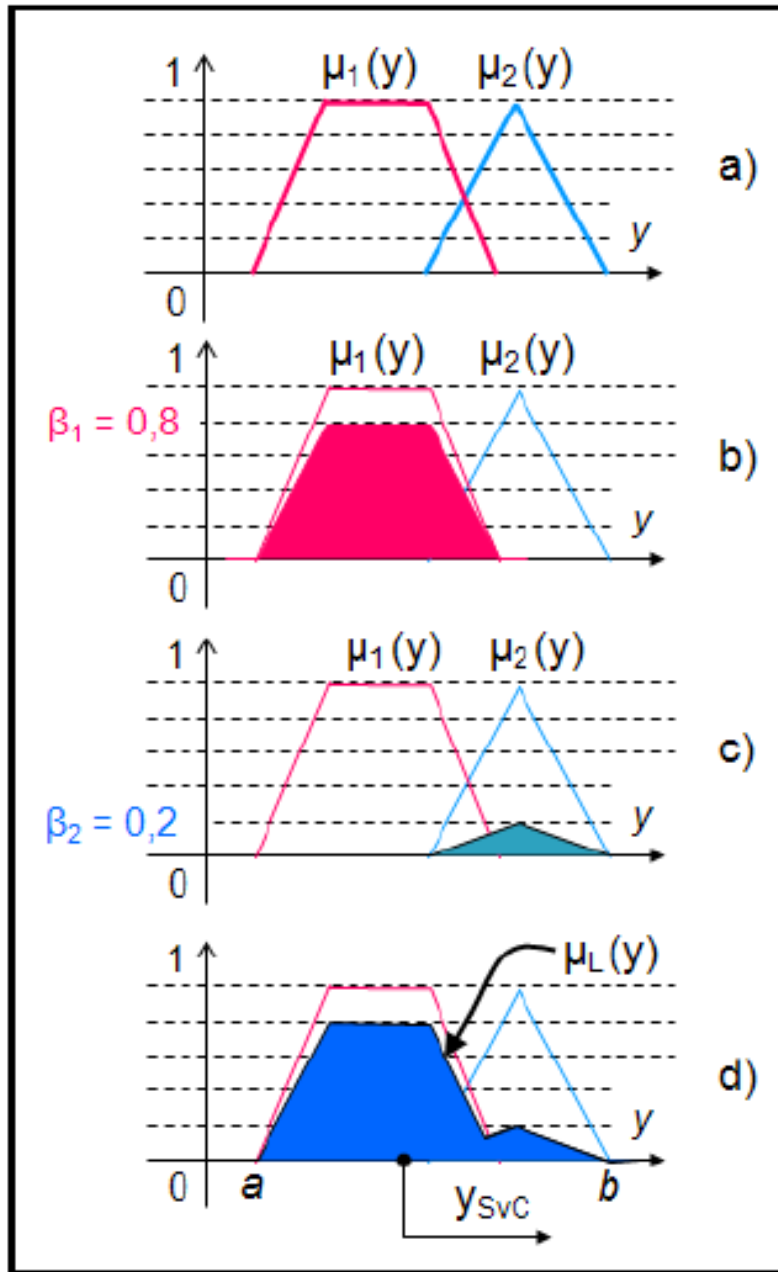
2 būdas. Larsono metodas

Loginės taisyklės, susijusios su i -tuoju miglotuoju rezultatu, teiginio tikrumo skaitinis įvertis β_i ir nuspręsties miglotojo rezultato y tikrumo funkcija $\mu_i(y)$ sujungiami paprasčiausia daugybos operacija.

$$\mu_L(y) = \max_i [\beta_i \times \mu_i(y)]$$

$$y_{SvC} = \frac{\int_a^b y \mu_L(y) dy}{\int_a^b \mu_L(y) dy}$$

Larsono metodas



- *Nuspręsties bloko rezultatai, gauti Mamdani ir Larsono metodais gali būti skirtingi.*
- Jų taikymas priklauso nuo ekspertų patirties

Miglotųjų ekspertinių planų įvairovė


Miglotųjų ekspertinių planų įvairovę apsprendžia faktoriai:

- 1) Analizuojamų reiškinių įvairovė;
- 2) Miglotųjų pažintinių planų įvairovė.

Eil Nr.	Miglotojo pažintinio plano tipas	Miglotojo ekspertinio plano tipas
1	MPP	MEP
2	N-MPP (netiesinis MPP)	N-MEP (netiesinis miglotasis ekspertinis planas)
3	D-MPP (dinaminis MPP)	D-MEP (dinaminis miglotasis ekspertinis planas)
4	ND-MPP (netiesinis dinaminis MPP)	ND-MEP (netiesinis dinaminis miglotasis ekspertinis planas)

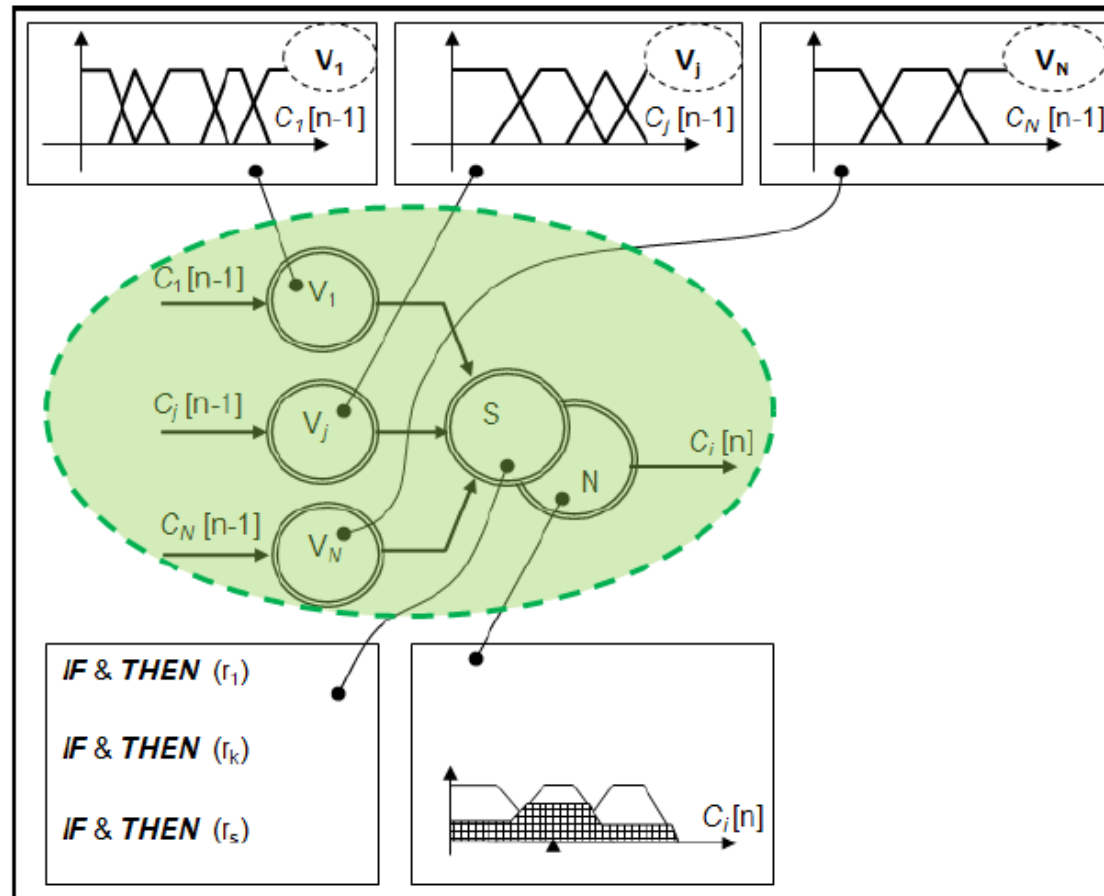
MEP – ekspertinio plano tipas

- Sumatoriuje Φ apskaičiuojama visų i -tojo mazgo įtakų C_1-C_N suma $\alpha_{i\Sigma}$ ir ji perduodama verbalizavimo blokui V .
- Rezultatai apdorojami bloke S pagal ekspertines ML taisykles.
- Pagal kiekvieną taisyklių sąrašo eilutę tikrumo skaitiniai įverčiai perduodami į nuspręsties bloką N , kurio išėjime pagal *Mamdani* ar *Larsono* metodą gaunamas mazgo esybės įvertis C_i



N-MEP – ekspertinio plano tipas

- Vertinama kiekvieno mazgo įtaka. N-MEP mazge kiekvienos įtakos verbalizavimas atliekamas skirtingai.
- Verbalizavimo operacijų rezultatai iš visų verbalizavimo blokų V_1 - V_N apdorojami samprotavimų bloke S ir nuspręsties bloke N .



MEP pavyzdžiai

Nagrinėjama JAV ir Irako santykių konfliktinė situacija, susidariusi Irake dėl pilietinio karo ir kt. priežasčių.

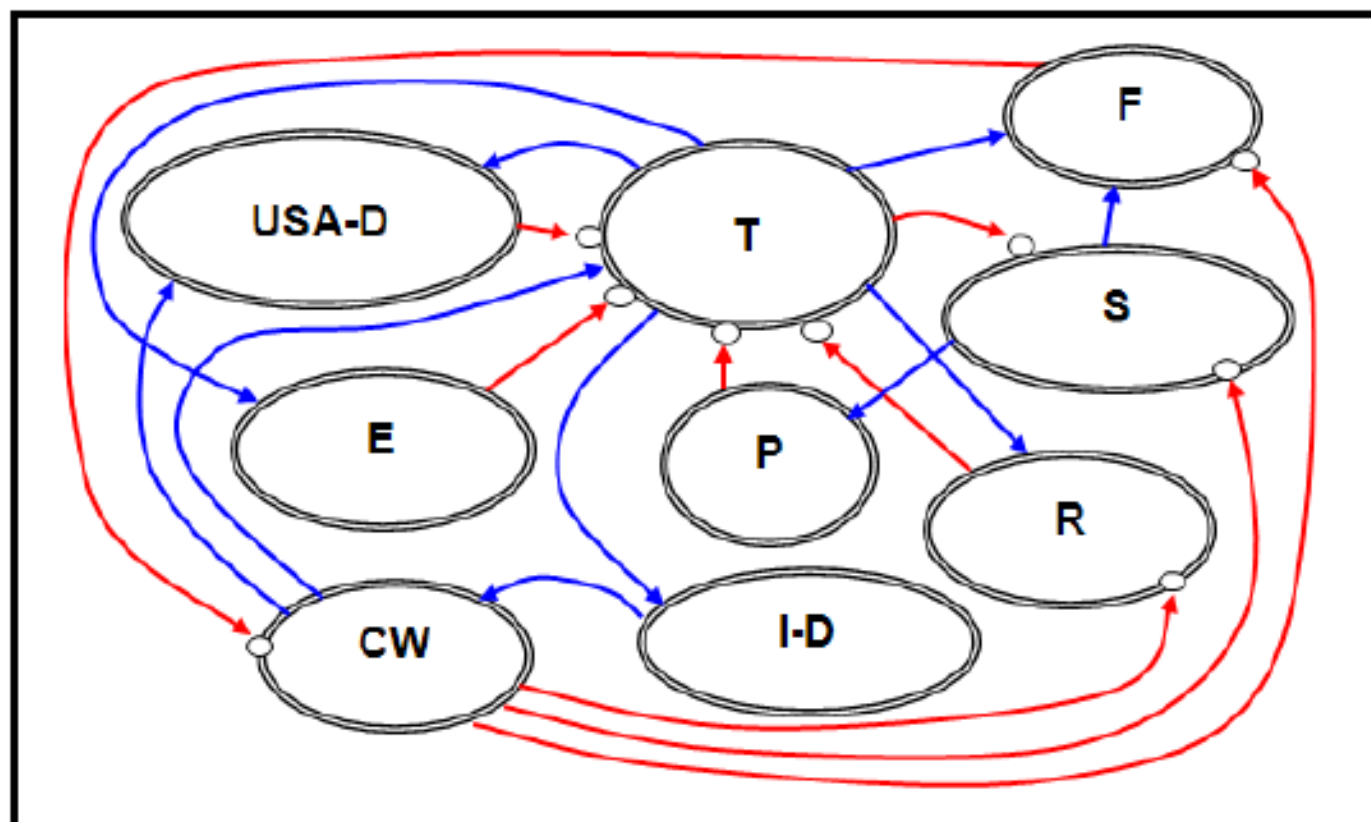
Ekspertų nuomone, situaciją apsprendžia tokių esybių sąveika:

- T – okupacijos trukmė,
- F – infrastruktūros statybų mastas,
- S – suvereniteto lygmuo,
- R – vietinės policijos patikimumas,
- I-D – žuvusių irakiečių skaičius,
- USA-D – žuvusių JAV karių skaičius,
- E – okupacijos kaštai,
- P – vietinių policininkų skaičius,
- CW – pilietinio karo intensyvumas .

Esybių sąveika

<div> <div>Įtakojamoji esybė C_j</div> <div>Įtakojančioji esybė C_i</div> </div>	T	F	S	R	$I-D$	$USA-D$	E	P	CW
T – okupacijos trukmė		+1	-1	+1	+1	+1	+1		
F – infrastruktūros statybų mastas									-1
S – suvereniteto lygmuo		+1						+1	
R – vietinės policijos patikimumas	-1								
$I-D$ – žuvusių irakiečių skaičius									+1
$USA-D$ – žuvusių JAV karių skaičius	-1								
E – okupacijos kaštai	-1								
P – vietinių policininkų skaičius	-1								
CW – pilietinio karo intensyvumas	+1	-1	-1	-1		+1			

Įtakojamoji esybė C_j Įtakojančioji esybė C_i	T	F	S	R	$I-D$	$USA-D$	E	P	CW
T – okupacijos trukmė		+1	-1	+1	+1	+1	+1		
F – infrastruktūros statybų mastas									-1
S – suvereniteto lygmuo		+1						+1	
R – vietinės policijos patikimumas	-1								
$I-D$ – žuvusių irakiečių skaičius									+1
$USA-D$ – žuvusių JAV karių skaičius	-1								
E – okupacijos kaštai	-1								
P – vietinių policininkų skaičius	-1								
CW – pilietinio karo intensyvumas	+1	-1	-1	-1		+1			



MEP sprendimas (1)


- Dalyvaujančių esybių įverčių įtaka į T esybę vienam modeliavimo žingsnyje $[n-1]$

$C_k[n-1]$		w_{ik}		$W_{ik}C_k[n-1]$
Esybė	Įvertis	Įtaka	Įvertis	
$USA-D[n-1]$	0,35	w_{TUSA-D}	-0,25	-0,0875
$CW[n-1]$	0,80	w_{TCW}	1,00	0,80
$E[n-1]$	0,87	w_{TE}	-0,10	-0,087
$P[n-1]$	0,93	w_{TP}	-0,25	-0,2325
$R[n-1]$	0,50	w_{TR}	-0,40	-0,20
				$\Sigma = 0,193$

MEP sprendimas (2)

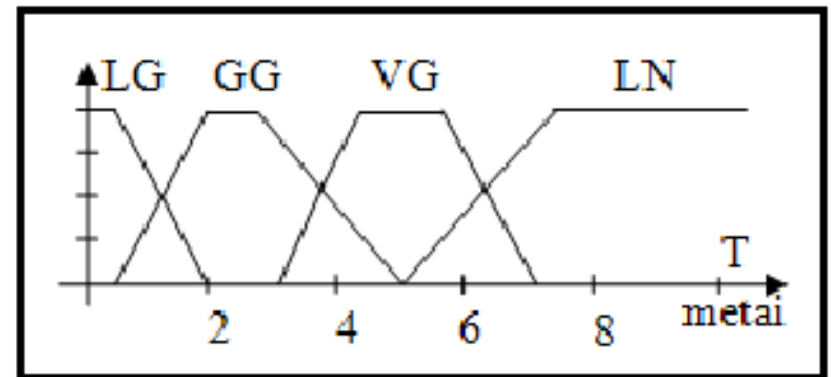
Sumarinė įtaka $\alpha_{T\Sigma}[n-1]$
charakterizuojama taip:

- M – maža;
- V – vidutinė;
- D – didelė;
- LD – labai didelė.

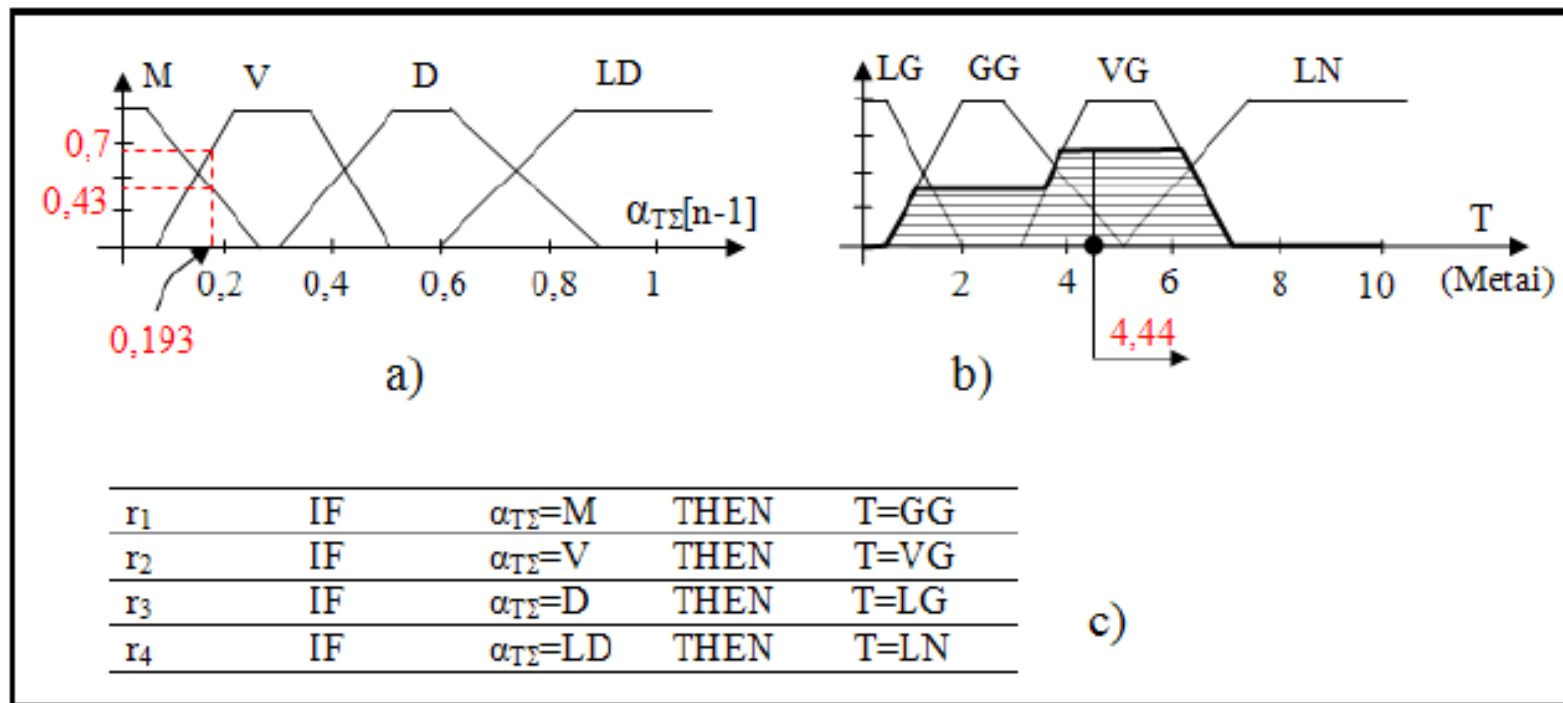


Kontingento išvedimo momentas miglotai
charakterizuojamas taip:

- LG – labai greitai;
- GG – ganėtinai greitai;
- VG – vidutiniškai greitai;
- LN – labai negreitai.








MEP sprendimas (3)



- 1) Skaičiuojama suminė įtaka (0,193)
- 2) Rezultatas. Mamdani tipo nuspręsties blokas pateikia T esybės įvertį **T=4,44 metų**

N-MEP sprendimas

Kiekvienam N-MEP mazgui ekspertai nustato kiekvienos įtakos verbalizavimo bloko miglotųjų įverčių TF kiekį ir jų tipus.

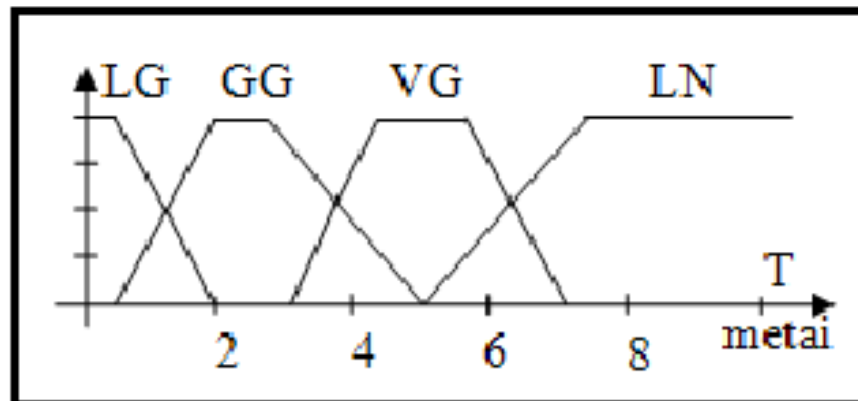


Įverčiai

Miglotųjų teiginių tikrumas nusakomas įverčiais:

- M – maža;
- P – priimtina;
- V – vidutinė;
- D – didelė;
- LD – labai didelė.

T esybės verbalinių įverčių tikrumo funkcijos:




Samprotavimo taisyklių sąrašo fragmentas

r1	IF	$E = V$	&	$USA-D = P$	THEN	$T = LN$
r2	IF	$E = D$	&	$USA-D = P$	THEN	$T = VG$
r3	IF	$E = V$	&	$USA-D = D$	THEN	$T = VG$
r4	IF	$E = D$	&	$USA-D = D$	THEN	$T = LG$
r5	IF	$P = D$	&	$R = P$	THEN	$T = VG$
r6	IF	$P = V$	&	$R = P$	THEN	$T = LN$
r7	IF	$P = D$	&	$R = V$	THEN	$T = VG$
r8	IF	$P = V$	&	$R = V$	THEN	$T = LG$
r9	IF	$CW = LD$	&	$P = V$	THEN	$T = LN$
r10	IF	$CW = LD$	&	$P = D$	THEN	$T = LN$
r11	IF	$CW = D$	&	$P = D$	THEN	$T = VG$
r12	IF	$CW = D$	&	$P = V$	THEN	$T = VG$

Samprotavimų lentelė pagal taisykles

r1	IF	$E = 0.45$	&	$USA-D = 0.25$	THEN	$T = LN = 0.25$
r2	IF	$E = 0.80$	&	$USA-D = 0.25$	THEN	$T = VG = 0.25$
r3	IF	$E = 0.45$	&	$USA-D = 0.75$	THEN	$T = VG = 0.45$
r4	IF	$E = 0.80$	&	$USA-D = 0.75$	THEN	$T = GG = 0.75$
r5	IF	$P = 0.85$	&	$R = 0.80$	THEN	$T = GG = 0.80$
r6	IF	$P = 0.20$	&	$R = 0.80$	THEN	$T = LN = 0.20$
r7	IF	$P = 0.85$	&	$R = 0.45$	THEN	$T = VG = 0.45$
r8	IF	$P = 0.20$	&	$R = 0.45$	THEN	$T = LN = 0.20$
r9	IF	$CW = 0.80$	&	$P = 0.20$	THEN	$T = LN = 0.20$
r10	IF	$CW = 0.80$	&	$P = 0.85$	THEN	$T = LN = 0.80$
r11	IF	$CW = 0.30$	&	$P = 0.85$	THEN	$T = VG = 0.30$
r12	IF	$CW = 0.30$	&	$P = 0.20$	THEN	$T = VG = 0.20$

Nuspręsties rezultatai



1 kreivė – Mamdani nuspręstis pagal $r1-r4$ taisykles;

2 kreivė – nuspręstis pagal $r5-r8$ taisykles;



3 kreivė - nuspręstis pagal $r9-r12$ taisykles.

Gautas rezultatas:

Rekomendaciją išvesti JAV karinį kontingentą iš Irako po 5,6 metų.

Pavyzdys. Prekės paklausa

Tarkime prognozuojama prekės paklausa. Turime: paklausa 270 kg., o valiutos kursas yra 6,78 Lt. Iš priklausomumo funkcijų grafikų randame $m_{\text{didelė paklausa}}(270)=0,7$ ir $m_{\text{vidutinis kursas}}(6,78)=0,2$



Taisyklėje: Jei *paklausa didelė* ir *kursas vidutinis*, tai *rinka palanki*

Sąlygos S teisingumas yra

$$t = m_{\text{rinka palanki}}(y) = \min\{0,7; 0,2\} = 0,2$$

Pavyzdys

Bet tas pats 6,78 Lt valiutos kursas iš dalies yra geras, nes

$$m_{\text{geras kursas}}(6,78)=0,8.$$

Tos pačios bazės kitos taisyklės:

Jei *paklausa didelė* ir *kursas geras*, tai ***rinka labai palanki***

Išvados teisingumas yra palyginti didelis

$$t = m_{\text{rinka labai palanki}}(y)=\min\{0,7;0,8\}=0,7$$

Mišrus metodas

Taisyklėje *Je*i S tai *išvada* teiginys S sudarytas iš teiginių S_1, S_2, \dots, S_n , kurie sujungti įvairiais loginių veiksmų ženklais.

Pavyzdys. Duota taisyklė

Jei S_1 arba (S_2 ir S_3) tai *išvada*,

kurioje $m_{S1}(x_1)=0,8$, $m_{S2}(x_2)=0,6$, $m_{S3}(x_3)=0,4$.

Sąlygos teisingumas gali būti randamas vienu iš šių keturių būdų:

$$t_1 = \max \{ m_{S1}(x_1); \min \{ m_{S2}(x_2); m_{S3}(x_3) \} \} = \\ \max \{ 0,8; \min \{ 0,6; 0,4 \} \} = \max \{ 0,8; 0,4 \} = 0,8;$$

$$t_2 = \max \{ m_{S1}(x_1); \text{prod} \{ m_{S2}(x_2); m_{S3}(x_3) \} \} = \\ \max \{ 0,8; 0,6 \cdot 0,4 \} \} = \max \{ 0,8; 0,24 \} = 0,8;$$

$$t_3 = \text{probor} \{ m_{S1}(x_1); \min \{ m_{S2}(x_2); m_{S3}(x_3) \} \} = \\ \text{probor} \{ 0,8; \min \{ 0,6; 0,4 \} \} = \text{probor} \{ 0,8; 0,4 \} = 0,8 + 0,4 - 0,8 \cdot 0,4 = 0,88;$$

$$t_4 = \text{probor} \{ m_{S1}(x_1); \text{prod} \{ m_{S2}(x_2); m_{S3}(x_3) \} \} = \\ \text{probor} \{ 0,8; 0,6 \cdot 0,4 \} \} = 0,8 + 0,24 - 0,8 \cdot 0,24 = 0,848.$$

Implikacija


- Neraiškiojoje logikoje nustačius išvadų teisingumą, modifikuojamos šių išvadų priklausomumo funkcijos $m_{\text{išvada}}(y)$, atsižvelgiant į nustatytuosius teisingumus t . Šis procesas vadinamas *implikacija*.
- Dažniausiai naudojami implikacijos metodai yra *min* ir *prod* metodas.

Literatūroje modifikuotas funkcijas žymi $m^t_{\text{išvada}}(y)$ ir vadina aktyvuotomis išvadų priklausomumo funkcijomis.

Min implikacijos metodas

Tarkime pagal kurią nors žinių bazės taisyklę buvo gauta išvada “rinka labai palanki” ir tarkim nustatytas teisingumas $t=0,7$.

- $m^{0,7}_{rinka\ labai\ palanki}(y) = \min\{0.7, m_{rinka\ labai\ palanki}(y)\}$




Prod implikacijos metodas

Aktyvuotoji priklausomumo funkcija gaunama pagal formulę

$$\hat{m}_{i\varepsilon vada}^t(y) = t m_{i\varepsilon vada}(y)$$

t.y. grafiko aukštis sumažinamas t kartų





Agregacija

Veiksnyys nors ir įgijęs vieną konkrečią reikšmę gali priklausyti keliems neraiškiesiems lygiams. Todėl pritaikius žinių bazės taisykles gali būti gaunamos skirtingos išvados.

Pvz., prekės paklausa 320 kg, valiuto kursas 6,78 Lt.

Taisyklės:

- Jei *paklausa didelė* ir *kursas vidutinis*, tai *rinka palanki*
- Jei *paklausa didelė* ir *kursas geras*, tai *rinka labai palanki*




min implikacijos metodas

Prekės paklausa 320 kg, valiuto kursas 6,78 Lt.

- Jei *paklausa didelė* ir *kursas vidutinis*, tai *rinka palanki*

$$m_{didele\ paklausa}(320)=1 \quad ir \quad m_{vidutinis\ kursas}(6,78)=0.3$$

implikacijos *min* metodą $m^{0,3}_{rinka\ palanki}(y)$




min implikacijos metodas

Prekės paklausa 320 kg, valiuto kursas 6,78 Lt.

- Jei *paklausa didelė* ir *kursas geras*, tai *rinka labai palanki*

$$m_{didele\ paklausa}(320)=1 \quad ir \quad m_{geras\ kursas}(6,78)=0.7$$

implikacijos *min* metodą $m^{0,7}_{rinka\ labai\ palanki}(y)$




Agregacija

Neraiškiojoje logikoje visos aktyvuotosios priklausomumo funkcijos sujungiamos į vieną bendrą funkciją, kuri vadinasi agreguota priklausomumo funkcija. Agregacijos būdai:

Max metodas. Agreguotosios funkcijos vertė taške y lygi didžiausiai iš visų aktyvuotų priklausomumo funkcijų verčių tame pačiame taške y .


$$m(y) = \max\{m_{S1}(y); m_{S2}(y); \dots m_{Sn}(y)\}$$



Agregācijas būdai

Sum metodes. Agreguotoji funkcija gaunama algebriškai sudedant aktyvuotāsias priklausomumo funkcijas.

$$m(y) = m_{s1}(y) + m_{s2}(y) + \dots + m_{sn}(y)$$



Agregācijas būdai

Probor metoas.


$$m(y) = m_{S1}(y) + m_{S2}(y) - m_{S1}(y) \cdot m_{S2}(y)$$



Defuzifikacija

- *Defuzifikacija* – iš agreguotosios išvadų priklausomumo funkcijos $m(y)$ y skaitinės vertės radimas.
- *Svorio centro* arba *centro* metodo


$$y_0 = \frac{\int_{y_{\min}}^{y_{\max}} ym(y)dy}{\int_{y_{\min}}^{y_{\max}} m(y)dy}$$



Defuzifikacija

- Ploto centro* arba *bisector* metodas. Defuzifikuota vertė laikomas taškas y_0 , tenkinantis lygybę:


$$\int_{y_{\min}}^{y_0} m(y) dy = \int_{y_0}^{y_{\max}} m(y) dy$$



Defuzifikacija

- Maksimumų vidurkio arba mom* metodas. Defuzifikuota vertė y_0 laikoma tų y verčių, kurios atitinka agreguotosios funkcijos didžiausias vertes vidurkis:


$$y_0 = \text{mean}\{y : m(y) = \max\{m(y)\}\}$$



Defuzifikacija

- Maksimumų mažiausios vertės arba som* metodas. Defuzifikuota vertė y_0 laikoma mažiausia iš tų y verčių, kurios atitinka agreguotosios funkcijos didžiausias vertes:

$$y_0 = \min\{ y : m(y) = \max\{ m(y) \} \}$$



Sugeno ir Takagi algoritmas

Pagrindinis skirtumas tarp Mamdani ir Sugeno yra tai, kad **Sugeno** modelio išėjimo funkcija yra arba tiesinė arba konstanta.

Sugeno modelį (trumpinys *TSK fuzzy modelis*) buvo pasiūlytas *Takagi*, *Sugeno* ir *Kang*. Tipinė Sugeno modelio fuzzy taisyklė pateikiama tokia forma:

If x is A and y is B then $z = f(x,y)$

Mamdani

If x is A and y is B then $z = C$

Pirmos eilės polinomas

If x is A and y is B then $z = f(x, y)$

A and **B** yra „antecedento“ fuzzy aibės, o $z = f(x, y)$ yra tiksli pasekmės funkcija.

Paprastai $f(\mathbf{x}, \mathbf{y})$ yra įėjimo \mathbf{x} ir \mathbf{y} polinomas (daugianaris). Tai gali būti bet kokia funkcija.

Kai $f(\mathbf{x}, \mathbf{y})$ yra pirmos eilės polinomas tai fuzzy išvadų sistema yra vadinama *pirmos-eilės Sugeno fuzzy modelis*, pavyzdžiui:

$$z = \mathbf{a}\mathbf{x} + \mathbf{b}\mathbf{y} + \mathbf{c}.$$

RULE#1:	IF	<u>TEMP</u> is COLD	THEN	<u>SPEED</u> = $j_1 + k_1 * T$
RULE#2:	IF	<u>TEMP</u> is COOL	THEN	<u>SPEED</u> = $j_2 + k_2 * T$
...	

Nulinės eilės fuzzy Sugeno modelis

- Kai f funkcija yra konstanta, turime nulinės eilės Sugeno fuzzy modelį ($z = \mathbf{a}\mathbf{x} + \mathbf{b}\mathbf{y} + \mathbf{c}$, kur $(\mathbf{a} = \mathbf{b} = \mathbf{0})$). Tai gali būti traktuojamas kaip specialusis Mamdani atvejis.

RULE#1: IF TEMP *is* COLD THEN SPEED = k_1

RULE#2: IF TEMP *is* COOL THEN SPEED = k_2

RULE#3: IF TEMP *is* PLEASANT THEN SPEED = k_3

RULE#4: IF TEMP *is* WARM THEN SPEED = k_4

RULE#5: IF TEMP *is* HOT THEN SPEED = k_5

Nulinės eilės fuzzy Sugeno modelis

- Kiekviena taisyklė išėjimo lygiui z_i suteikia svorį panaudojant taisyklės stiprumo parametą w_i . Tarkime AND taisyklei su $\text{įėjimu1} = x$ ir $\text{įėjimu2} = y$, stiprumas yra:

$$w_i = \text{AND_metodas}(F1(x), F2(y))$$

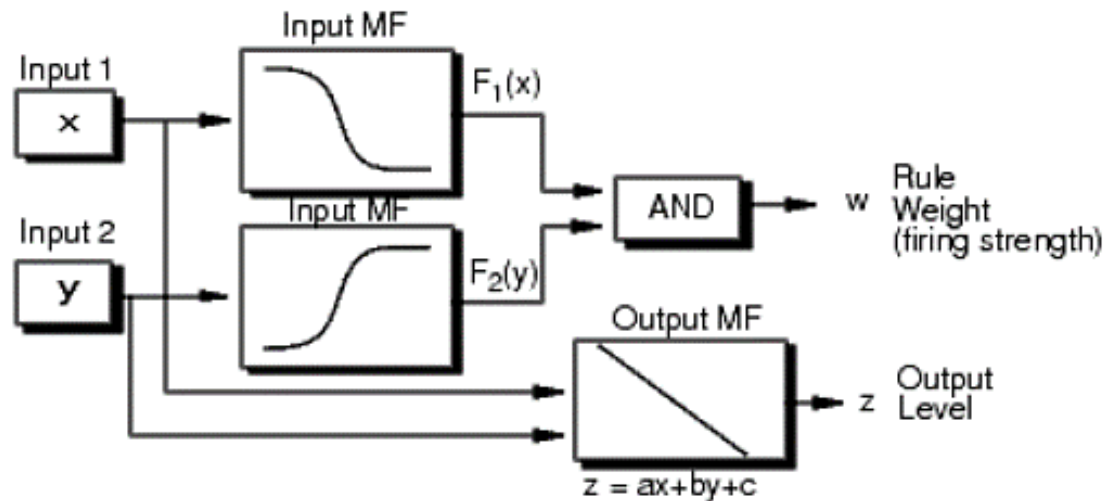
- Kur $F1(x)$, $F2(y)$ yra priklausomybės funkcijos įėjimui1 ir įėjimui2 .

Galutinis išėjimas

Galutinis modelio išėjimas yra visų taisyklių išėjimų svorinis vidurkis skaičiuojamas pagal formulę:

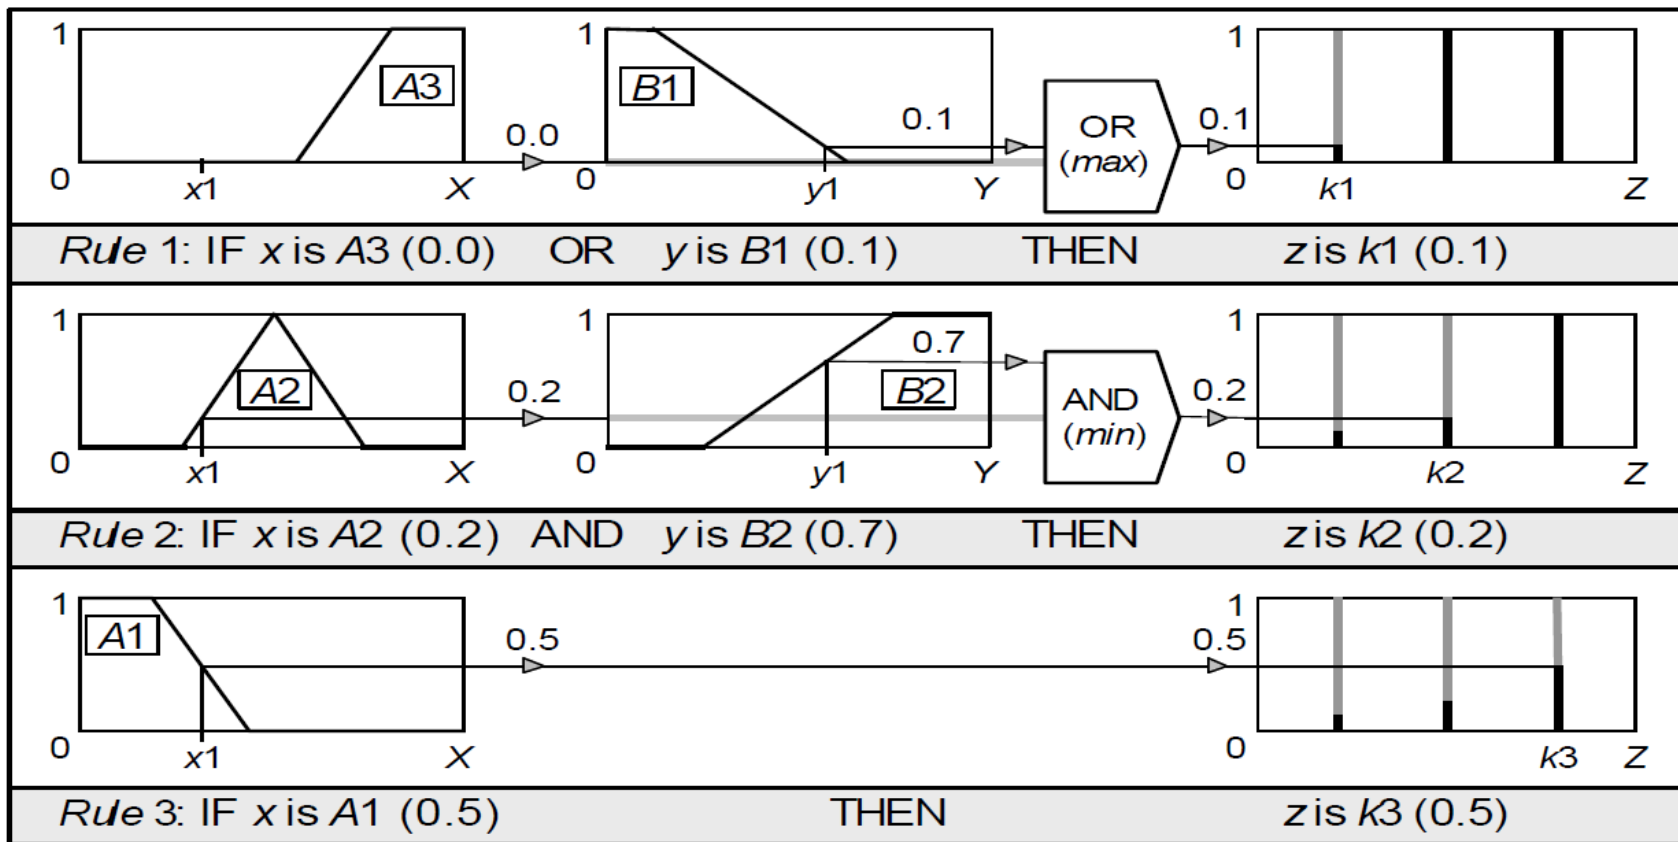
$$FinalOutput = \frac{\sum_{i=1}^N w_i z_i}{\sum_{i=1}^N w_i}$$

kur N - taisyklių skaičius.



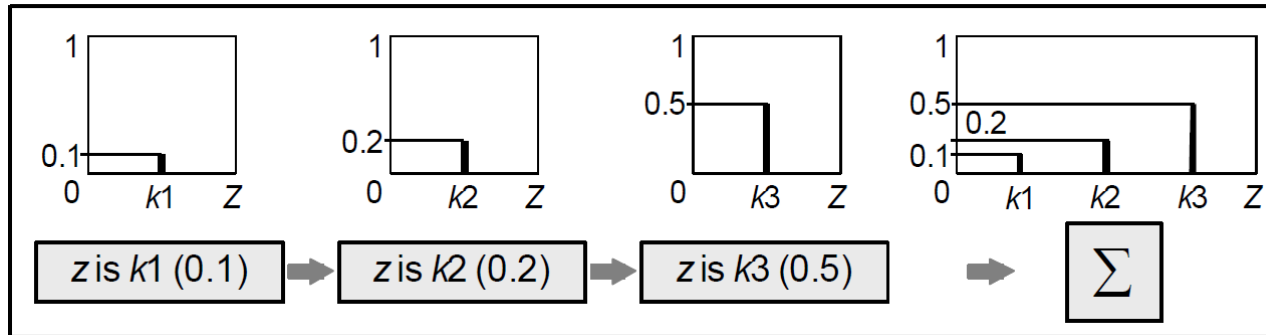
Pavyzdys (1)

- Sugeno taisyklių vertinimas



Pavyzdys (2)


- Sugeno taisyklių išėjimo agregacija



- Svorinis vidurkis

$$WA = \frac{\mu(k_1) \times k_1 + \mu(k_2) \times k_2 + \mu(k_3) \times k_3}{\mu(k_1) + \mu(k_2) + \mu(k_3)} = \frac{0.1 \times 20 + 0.2 \times 50 + 0.5 \times 80}{0.1 + 0.2 + 0.5} = 65$$

- Defuzifikacija



Apibendrinimas. Sugeno ir Takagi algoritmas

1. Priklausomumo funkcijų sudarymas;
2. Žinių bazės sudarymas iš specialaus pavidalo taisyklių

$$\text{Jei } S_1(x_1) \text{ ir } s_2(x_2) \text{ tai } z_j = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2$$

čia $S_i(x_i)$ yra teiginiai apie veiksnio priklausymą vienam ar kitam neraiškiam lygmeniui, x_i yra skaitinis nefuzifikuotas kintamasis, reiškiantis veiksnio vertę, j yra taisyklės numeris, o koeficientus α_i parenka ekspertas. Kiekvienai taisyklei šie koeficientai bendru atveju gali būti skirtingi. Jei koeficientas $\alpha_1 = \alpha_2 = 0$, t.y. $z_j = \alpha_0 = \text{const}$, tai algoritmas vadinamas nulinės eilės Sugeno-Takagi algoritmu, o priešingu atveju pirmos eilės.

Pvz. Taisyklė:

jei *didele paklausa* (x_1) ir *geras kursas* (x_2) tai $z = 11x_0 + 140x_2$
yra pirmos eilės modelis, kur z yra pelnas.

Sugeno ir Takagi algoritmas

3. **Fuzifikacija.** Randami kintamųjų vertės atitinkantys lingvistiniai kintamieji ir jų priklausomumo funkcijų vertės
4. **Sudėtinių sąlygų sudarymas, išvadų ir jų teisingumo radimas.** Pagal duotas neraiškiųjų veiksnių vertes x_1 ir x_2 , pasinaudojant priklausomumo funkcijomis ir žinių baze, randamos išvados, t.y. Funkcijos z_j skaitinės vertės ir jų teisingumai t_j
5. **Defuzifikacija.** Randama visų išvadų z_j bendra skaitinė vertė z_0 svertinio vidurkio metodu arba svertinės sumos metodu.

$$z_0 = (t_1 z_1 + t_2 z_2) / t_1 + t_2 \quad \text{arba} \quad z_0 = t_1 z_1 + t_2 z_2$$

Literatūra

1. **Jasinevičius R., Petrauskas V.** Sprendimų pagrindimo kompiuterizavimas, 2011.
2. **Purvinis O., Šukys P.** Neraiškioji logika ir jos praktiniai taikymai, 2012.